

UNIVERSIDADE FEDERAL DE SERGIPE
DEPARTAMENTO DE COMPUTAÇÃO
QUALIDADE DE SOFTWARE

Métricas automáticas versus avaliação humana (GQM) | Ciclo de vida e versionamento de sistemas generativos
Projeto: Crawl4AI - Extração web e rastreabilidade para RAG

Equipe 02:
Brício Thyers de Gois Macedo
Carlos Eduardo Laurentino dos Santos
Daniel Rodrigo Ferreira dos Santos
Letícia Rezende dos Santos
Lucas Conceição Celestino
Maria Rita Melo de Souza
Rivaldo José Nascimento dos Santos

Repositório da Equipe: https://github.com/daniel-dev2/QS_2026-2_crawl4ai_Atividade3
Repositório do Projeto analisado: https://github.com/unclecode/crawl4ai
Link do vídeo no Youtube: https://youtu.be/1AWzGdqc-mg
Link do vídeo no Drive: link para o video no drive

Sumário

Introdução....3
Padronizações para os experimentos:.... 3
1. Planejamento Experimental com GQM (Goal-Question-Metric).... 3
1.1 Tabela do Planejamento....4
1.2 Parâmetros e Critérios Experimentais Prévios.... 5
Limiar Automático (tau).... 5
Rubrica e Critério de Aprovação Humana....5
Condições de Falha Crítica (FC = 1)....6
1.3 Protocolo de Decisão Experimental (Avanço vs. Bloqueio).... 6
2. Casos de testes....7
3. Execução dos testes....8
3.1 Saídas por caso e versão.... 8
4. Avaliação Humana Principal.... 9
4.1 Critérios da Avaliação Humana....9
4.2 Resultados da Avaliação Humana.... 9
4.3 Comparação das Taxas de Aprovação Humana....10
4.4 Análise das Falhas e Limitações Identificadas....11
4.5 Considerações sobre os Resultados da Avaliação Humana....11
5. Avaliação automática: F1 lexical.... 12
5.1 Definição operacional (fixada antes da interpretação)....12
5.2 Resultados.... 13
5.3 Leitura dos resultados....14
5.4 Concordância automático–humano (M3).... 14
5.5 Limitações da medida.... 15
7. Avaliação Humana Secundária (R2)....17
7.1 Resultados da R2....17
7.2 Comparação com R1.... 17
7.3 Diagrama de Ciclo de Vida....18
Declaração Uso de IA.... 20

Introdução

O Crawl4AI é um web crawler e scraper de código aberto, ou seja, um programa automatizado que lê, coleta, mapeia o conteúdo de sites e os estrutura. Ele é licenciado sob Apache 2.0, construído sobre as bibliotecas Playwright (usada em automação de navegador) e asyncio (usada para concorrência em Python). O projeto tem mais de 70 mil estrelas no GitHub, sendo um dos crawlers mais populares voltados especificamente para alimentar aplicações de Inteligência Artificial.

O diferencial central do Crawl4AI em relação a um scraper tradicional é ser descrito por seus próprios mantenedores como "LLM-friendly": em vez de devolver HTML bruto, a ferramenta entrega o conteúdo das páginas já convertido em Markdown limpo (removendo menus, rodapés e anúncios por meio de filtros de conteúdo) ou em JSON estruturado, obtido por meio de estratégias de extração que podem ou não envolver um modelo de linguagem. Essa característica torna o Crawl4AI particularmente relevante para pipelines de Retrieval-Augmented Generation (RAG), nos quais o conteúdo extraído da web alimenta diretamente uma base de conhecimento consultada por um assistente de IA generativa.

Padronizações para os experimentos:

- Repositório do projeto: https://github.com/unclecode/crawl4ai.
- Licença: Apache 2.0.
- Modelo de linguagem utilizado: Qwen/Qwen3-4B.
- Ambiente de execução: Google Colab, com GPU NVIDIA Tesla T4.
- Tecnologias de suporte: Python, PyTorch, CUDA, Playwright e asyncio.
- Configuração do ambiente: PyTorch 2.11.0+cu128, CUDA 12.8 e 14,56 GB de memória de GPU.

1. Planejamento Experimental com GQM (Goal-Question-Metric)

Para avaliar a evolução do fluxo de extração de dados do Crawl4AI e confrontar sinais automáticos com a avaliação humana de acordo com as diretrizes da Atividade 3, adotou-se o paradigma Goal-Question-Metric (GQM).

O experimento compara duas versões do fluxo de extração estruturada:

- **Versão A (Baseline):** Fluxo com extração direta ou prompt padrão (P2 da Atividade 2), sujeito a falhas de consistência estrutural e alucinações de links.
- **Versão B (Evoluída):** Fluxo com alteração isolada no prompt/extração (incorporando restrições explícitas de não omissão de chaves, política de abstenção e obrigatoriedade de ancoragem factual nos trechos coletados).

1.1 Tabela do Planejamento

Nível GQM	**Descrição / Definição**	**Medida Operacional**	**Unidade**	**Fórmula e Denominador**	**Limitações Declaradas**
Objetivo (Goal)	Avaliar o impacto da melhoria do prompt na confiabilidade das saídas estruturadas do Crawl4AI e verificar a concordância do sinal automático frente à avaliação humana.	Não aplicável	Não aplicável	Não aplicável	Amostra reduzida a 6 casos de teste com 1 execução por caso/versão (12 saídas no total).
Pergunta 1 (Q1)	A Versão B atende melhor à tarefa de extração estruturada e conformidade semântica do que a Versão A?	**M1: Taxa de Aprovação Humana**	Proporção / Porcentagem	Taxa = (Total de Casos Aprovados) / 6, avaliada por versão (denominador fixo em 6).	Depende da calibração subjetiva do avaliador humano; vulnerável a variações de rigor na interpretação da rubrica.
Pergunta 2 (Q2)	O sinal da métrica automática (F1 lexical por tokens)	**M2: F1 Lexical por Tokens**	Escala contínua [0.00, 1.00]	F1 = 2 * (P_tok * R_tok) / (P_tok + R_tok). P_tok	Penaliza paráfrases corretas e sinônimos legítimos;

Nível GQM	Descrição / Definição	Medida Operacional	Unidade	Fórmula e Denominador	Limitações Declaradas
	representa a adequação factual e o julgamento humano?			= comuns / tokens_resposta; R_tok = comuns / tokens_ref.	sensível a formats e pontuação; não avalia a validade do schema JSON.
Pergunta 2 (Q2)	Em que medida o sinal automático concorda com o veredito final dos avaliadores humanos?	**M3: Taxa de Concordância Automático-Humano**	Proporção / Porcentagem	Concordância = (Total de Decisões Idênticas entre Sinal Automático e Decisão Humana) / 12 (denominador fixo em 12).	O limiar TAU fixado a priori pode gerar falsos positivos ou falsos negativos sem refletir adequação semântica real.

1.2 Parâmetros e Critérios Experimentais Prévios

Limiar Automático (tau)

- **Valor fixado a priori:** tau = 0.50.
- **Regra de Decisão Automática:** Se F1_lexical >= 0.50, a resposta é classificada como 'Aprovada'; se F1_lexical < 0.50, 'Reprovada'.

Rubrica e Critério de Aprovação Humana

A avaliação humana aplica notas inteiras (0, 1 ou 2) nas seguintes dimensões:

1. **Correção:** 0 = Erro substantivo; 1 = Parcial/erro menor; 2 = Sem erro identificado na referência.

2. **Relevância:** 0 = Não atende; 1 = Atende parcialmente; 2 = Atende plenamente, inclusive abstenção correta.
3. **Suporte:** 0 = Sem suporte na fonte; 1 = Suporte parcial; 2 = Afirmações integralmente sustentadas na fonte ou abstenção justificada.

Critério de Aprovação Humana: Uma saída é considerada estritamente aprovada se, e somente se, receber nota 2 nas três dimensões (Correção = 2, Relevância = 2, Suporte = 2) E apresentar ausência de falha crítica (Falha Crítica = 0).

Condições de Falha Crítica (FC = 1)

Registra-se falha crítica bloqueante caso ocorra qualquer uma das seguintes violações:

- **Alucinação Factual:** Invenção de fatos, dados numéricos ou entidades não sustentados pela fonte fornecida.
- **Não Abstenção no Caso Limite (CT05):** Afirmação categórica ou fabricação de resposta em cenário de evidência insuficiente/ausente.
- **Corrupção de URL:** Fornecimento de URLs inexistentes, pseudoprotocolos (ex: javascript:void(0)), caminhos relativos ou links alucinados.
- **Quebra Estrutural:** Geração de JSON malformado que viole a decodificação sintática ou omissão de chaves obrigatórias.

1.3 Protocolo de Decisão Experimental (Avanço vs. Bloqueio)

A decisão entre manter a Versão A (baseline) ou avançar com a Versão B é determinada pelas seguintes regras:

- **Critério de Avanço para a Versão B:** A Versão B será recomendada para avanço se demonstrar superioridade na Taxa de Aprovação Humana (Taxa_Humana(B) > Taxa_Humana(A)) E registrar zero ocorrências de Falha Crítica em casos críticos (CT01 e CT05).
- **Condição de Bloqueio:** Se a Versão B apresentar ocorrência de Falha Crítica em CT01 ou CT05, ou se a Taxa de Aprovação Humana da Versão B for menor ou igual à da Versão A, o avanço é formalmente bloqueado, recomendando-se a manutenção da Versão A ou novo ciclo de refinamento de prompt.

- **Ressalva de Governança:** Esta decisão experimental constitui validação técnica em ambiente controlado e não autoriza implantação irrestrita em produção sem testes de carga e segurança adicionais.

2. Casos de testes

Foram definidos seis casos, sendo quatro funcionais (CT01 a CT04), um sem evidência suficiente (CT05) e uma variação de CT01 (CT06). Os casos funcionais cobrem extração básica de horário e prazo (CT01), fidelidade de valor monetário (CT02), fidelidade de datas (CT03) e exclusão de ruído de menu e rodapé (CT04). O CT05 apresenta uma página que informa apenas estar em manutenção, e a referência espera que o sistema declare a insuficiência de informação em vez de inventar dados. O CT06 reutiliza a página de CT01 com erros de digitação e uma frase parafraseada, preservando a intenção, para observar a robustez do fluxo. Por derivar de CT01, o CT06 não constitui observação independente.

As fontes são páginas HTML sintéticas e estáticas, servidas localmente em http://localhost:8000. Essa escolha garante que as versões A e B recebam exatamente a mesma entrada, torna o experimento reproduzível, evita dados sigilosos e elimina a dependência de sites externos, cujo conteúdo poderia mudar entre as execuções. Como a URL de cada caso é o endereço real da página no servidor local, o campo url da saída pode ser comparado diretamente com a referência.

Cada caso possui uma pergunta de verificação com resposta esperada (por exemplo, no CT01: “qual o horário de funcionamento e o prazo de empréstimo?”), para ser utilizada pelos avaliadores humanos para checar o JSON gerado.

Foram adotadas cinco regras de preenchimento, aplicadas igualmente aos prompts A e B: titulo é o texto do <h1>; url é a URL da página processada; conteudo é um resumo fiel do texto principal, sem menu, rodapé ou informação inventada; links são os do corpo principal da página (<main> ou <article>), excluindo menu e rodapé; e, na ausência de informação suficiente, o conteúdo deve declarar a limitação.

Limitações: seis casos sintéticos, curtos e estáticos não representam páginas reais, que têm HTML mais extenso e ruidoso, e não permitem concluir sobre o comportamento geral do fluxo.

3. Execução dos testes

Os seis casos foram executados nas versões A e B, uma vez por caso e versão, totalizando 12 saídas brutas. A execução usou o modelo Qwen/Qwen3-4B com o Crawl4AI 0.9.5, em Google Colab com GPU NVIDIA Tesla T4 (PyTorch 2.11.0+cu128, CUDA 12.8), e temperatura 0. As fontes foram servidas em http://localhost:8000 e são as mesmas nas duas versões. A única diferença entre elas é o prompt: a versão A usa o prompt p1 (“Extraia o título, a URL, o conteúdo e os links desta página.”) e a versão B usa o prompt p2, com as restrições de não omissão, abstenção e ancoragem factual.

3.1 Saídas por caso e versão

Caso	**Versão A**	**Versão B**
CT01	Vazia	Dados corretos
CT02	Vazia	Dados corretos
CT03	Dados corretos	Dados corretos
CT04	Vazia	Dados corretos, sem menu e rodapé
CT05	Vazia	Reproduz a mensagem da página, sem inventar dados
CT06	Vazia	Dados corretos, com erros de digitação copiados da fonte

Na versão A, 5 das 6 saídas ficaram vazias. Na versão B, todas as seis trouxeram conteúdo compatível com a fonte. A taxa de aprovação humana e o F1 não são apresentados nesta seção, porque dependem das avaliações R1 e R2 e do cálculo do F1.

Em CT05, a versão B não inventa dados, mas também não declara explicitamente que a informação é insuficiente; cabe ao avaliador humano decidir se isso atende ao critério de abstenção justificada. Em CT06, a saída preserva a informação de CT01, mas copia os erros de digitação da fonte (“funsiona”, “as 8h”), o que pode reduzir o F1 lexical sem que haja erro de conteúdo.

4. Avaliação Humana Principal

A partir da avaliação humana foi possível analisar a qualidade das 12 saídas produzidas pelas versões A e B, considerando a fidelidade das informações extraídas, o atendimento às perguntas dos casos de teste e a fundamentação das respostas nas fontes disponibilizadas. Foram analisados os contextos enviados ao modelo, as saídas brutas em JSON, as páginas HTML utilizadas como fontes e as respectivas respostas de referência dos seis casos de teste.Cada saída recebeu três notas independentes, variando de 0 a 2, conforme os critérios de correção, relevância e suporte definidos no planejamento experimental.

4.1 Critérios da Avaliação Humana

A avaliação realizada levou como base três critérios:

- **Correção:** verifica se as informações extraídas estão factualmente corretas e correspondem ao conteúdo da fonte.
- **Relevância:** verifica se a resposta atende ao objetivo da pergunta e contempla as informações solicitadas.
- **Suporte:** verifica se as afirmações apresentadas estão fundamentadas no conteúdo disponibilizado ao modelo.

Cada critério recebeu uma nota inteira de 0 a 2, sendo:

Nota	Interpretação
0	Critério não atendido.
1	Critério parcialmente atendido.
2	Critério plenamente atendido.

Uma resposta foi considerada aprovada quando recebeu nota 2 nos três critérios e não apresentou falha crítica, conforme a regra estabelecida no planejamento experimental.

4.2 Resultados da Avaliação Humana

Foram avaliadas as seis saídas da versão A e as seis saídas da versão B, totalizando 12 avaliações individuais. A tabela apresenta as notas atribuídas em cada dimensão. A ordem dos valores é Correção / Relevância / Suporte.

Caso	Versão A	Versão B

CT01	0 / 0 / 0 — Reprovada	2 / 2 / 2 — Aprovada
CT02	0 / 0 / 0 — Reprovada	2 / 2 / 2 — Aprovada
CT03	2 / 2 / 2 — Aprovada	2 / 2 / 2 — Aprovada
CT04	0 / 0 / 0 — Reprovada	2 / 2 / 2 — Aprovada
CT05	0 / 0 / 0 — Reprovada	1 / 1 / 2 — Reprovada
CT06	0 / 0 / 0 — Reprovada	2 / 2 / 2 — Aprovada

Na versão A, cinco saídas retornaram listas vazias, não apresentando os campos e as informações solicitadas. Por esse motivo, receberam nota zero nas três dimensões. A única saída aprovada foi a do CT03, que apresentou corretamente as informações de data, local e prazo de inscrição, fundamentadas na fonte.

Na versão B, cinco dos seis casos receberam nota máxima nos três critérios. O CT05 recebeu notas parciais em correção e relevância, pois, embora tenha reproduzido a mensagem de manutenção sem inventar um horário de atendimento, não declarou explicitamente a insuficiência de informações e apresentou o campo **`titulo`** com valor **`null`**.

4.3 Comparação das Taxas de Aprovação Humana

Com base nas avaliações individuais, foram calculadas as taxas de aprovação de cada versão, considerando os seis casos como denominador.

Indicador	Versão A	Versão B
Respostas avaliadas	6	6
Respostas aprovadas	1	5
Respostas reprovadas	5	1
Taxa de aprovação humana	16,7%	83,3%

A versão B apresentou uma taxa de aprovação humana significativamente superior à versão A, passando de 16,7% para 83,3%. Esse resultado representa uma melhora de 66,6 pontos percentuais na aprovação das respostas avaliadas.

A diferença é explicada principalmente pela recuperação das informações nos casos CT01, CT02, CT04 e CT06, que retornaram listas vazias na versão A e apresentaram dados adequados na versão B. No CT03, ambas as versões

produziram respostas corretas, enquanto o CT05 permaneceu como um caso de atendimento parcial.

4.4 Análise das Falhas e Limitações Identificadas

Durante a avaliação, foi identificada uma incompatibilidade estrutural nas saídas produzidas pelas duas versões.

Embora os arquivos gerados sejam JSON sintaticamente válidos, as respostas utilizam uma lista como estrutura raiz (`[]` ou `[objeto]`), enquanto o arquivo **`page_schema.json`** define um objeto como estrutura raiz.

Além disso, a saída do CT05 na versão B apresenta o campo **`titulo`** com valor **`null`**, apesar de o esquema exigir uma string.

Essa diferença demonstra que a validade sintática do JSON não garante sua conformidade com o esquema definido para a extração. Portanto, mesmo as respostas aprovadas pela avaliação de conteúdo devem ser consideradas aprovadas apenas segundo a regra operacional de notas, sem confirmação de conformidade estrutural.

Quanto às falhas críticas, os registros da avaliação mantiveram o valor zero provisoriamente, pois não foi possível confirmar a classificação formal da incompatibilidade estrutural identificada. Dessa forma, esse resultado não deve ser interpretado como comprovação de ausência de falhas críticas.

Outra limitação importante é que o CT06 representa uma variação do CT01, preservando sua intenção por meio de uma pergunta parafraseada e com erros de digitação. Assim, embora tenha sido avaliado individualmente, não deve ser considerado uma observação independente para generalizações sobre o desempenho do sistema.

4.5 Considerações sobre os Resultados da Avaliação Humana

Os resultados demonstram que a versão B apresentou melhor desempenho na extração e organização das informações solicitadas nos casos avaliados. Enquanto a versão A produziu apenas uma resposta aprovada, a versão B obteve cinco aprovações, demonstrando maior capacidade de recuperar informações relevantes e fundamentadas nas fontes.

Entretanto, o resultado do CT05 evidencia que a política de abstenção ainda pode ser aprimorada, especialmente na comunicação explícita da insuficiência de

informações. Além disso, a incompatibilidade entre a estrutura das respostas e o esquema JSON definido representa uma limitação que precisa ser considerada antes de qualquer conclusão sobre a confiabilidade integral da solução.

Assim, a partir da avaliação humana foi possível identificar uma evolução significativa no conteúdo das respostas da versão B, contudo não permite afirmar que todas as exigências estruturais foram atendidas.

5. Avaliação automática: F1 lexical

5.1 Definição operacional (fixada antes da interpretação)

A medida M2 foi calculada pelo script `atividade3/metricas/calculo_f1.py`, que lê as referências (`casos/referencias.json`) e as 12 saídas brutas (`execucoes/<versão>/<caso>/saida_bruta.json`) sem editá-las. As regras abaixo foram fixadas antes de se olhar o resultado por caso:

- **Texto comparado:** valores de `titulo`, `url`, `conteudo` e `links`, nessa ordem, sem as chaves do JSON e sem a pontuação sintática. `null` vira texto vazio. Saída `[]` vira texto vazio e recebe F1 = 0; ela é registrada e não descartada.
- **Normalização e tokenização:** Unicode NFC, `casefold` e tokens de palavras. Números com separador decimal (por exemplo, "18,90") formam um único token. Não há remoção de acentos nem de markdown.
- **Interseção:** de multiconjuntos (tokens repetidos contam até o mínimo de ocorrências nos dois textos).
- **Fórmulas:** P = comuns / tokens da resposta; R = comuns / tokens da referência; F1 = 2·P·R / (P + R). Sem sobreposição ou com resposta vazia, F1 = 0.
- **Sinal automático:** "aprova" se F1 ≥ τ, com τ = 0,50 (fixado na seção 1.2, antes da bateria e sem ajuste posterior).
- **Análise de sensibilidade (não oficial):** o script também calcula o F1 usando apenas `titulo` + `conteudo`, para mostrar quanto `url` e `links` (que são quase sempre copiados corretamente) elevam o F1. O sinal oficial usa o texto completo.

5.2 Resultados

Caso	Versão	Tokens resp.	Tokens ref.	Comuns	P	R	F1	Sinal (τ = 0,50)	F1 (só título + conteúdo)
CT01	A	0	34	0	0,000	0,000	0,000	reprova	0,000
CT02	A	0	26	0	0,000	0,000	0,000	reprova	0,000
CT03	A	53	36	36	0,679	1,000	0,809	aprova	0,712
CT04	A	0	28	0	0,000	0,000	0,000	reprova	0,000
CT05	A	0	18	0	0,000	0,000	0,000	reprova	0,000
CT06	A	0	34	0	0,000	0,000	0,000	reprova	0,000
CT01	B	53	34	34	0,641	1,000	0,782	aprova	0,689
CT02	B	43	26	26	0,605	1,000	0,754	aprova	0,605
CT03	B	53	36	36	0,679	1,000	0,809	aprova	0,712
CT04	B	37	28	28	0,757	1,000	0,862	aprova	0,800
CT05	B	12	18	7	0,583	0,389	0,467	reprova	0,200
CT06	B	54	34	29	0,537	0,853	0,659	aprova	0,516

Versão	F1 médio	F1 mediano	Aprovadas pelo sinal automático (denominador 6)
A	0,135	0,000	1/6
B	0,722	0,768	5/6

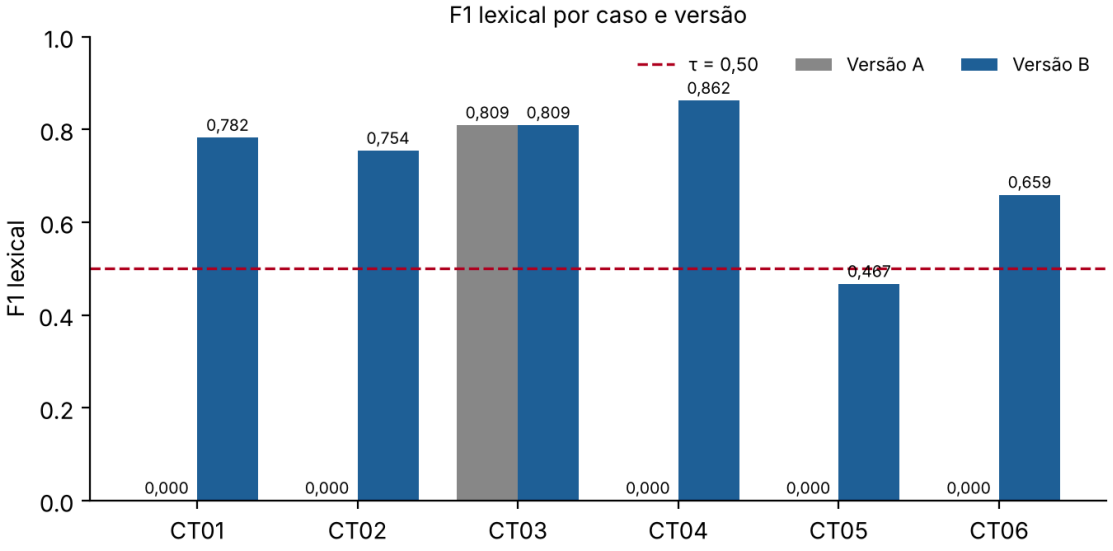


Figura 1 – F1 lexical por caso e versão (linha tracejada: τ = 0,50).

5.3 Leitura dos resultados

1. **O F1 separa saída vazia de saída preenchida.** Em A, cinco das seis saídas foram `[]` e receberam F1 = 0; em B, todas tiveram conteúdo. A diferença de médias (0,135 contra 0,722) reflete, sobretudo, isso.
2. **CT03 não distingue A de B.** As duas saídas são idênticas (mesmo hash em `registro_execucoes.csv`), com F1 = 0,809 nas duas versões. A melhora de B vem dos outros cinco casos.
3. **A precisão é o que limita o F1 das saídas corretas.** Em CT01–CT04 (B), o recall é 1,000 e a precisão fica entre 0,605 e 0,757, porque o modelo escreve os links em markdown dentro de `conteudo` (por exemplo, "Veja o [acervo](http://localhost:8000/acervo)…"), o que acrescenta tokens ausentes da referência. O F1 cai sem que haja erro de conteúdo.
4. **Limite do F1 (caso-limite principal): CT05 em B.** A saída copia a mensagem da página ("Estamos atualizando esta página. Volte em breve."), não inventa dados e devolve `links` vazio, mas não declara explicitamente a insuficiência de informação e traz `titulo` = `null`, embora a página tenha um `<h1>`. O F1 é 0,467, abaixo de τ (sinal "reprova"), e 0,200 se só título e conteúdo forem comparados. O resultado está perto do limiar e depende da redação da referência de abstenção. A avaliação humana também reprova a saída: o R1 deu correção 1, relevância 1 e suporte 2 (conteúdo literal e sem invenção, mas título ausente e insuficiência não explicitada), e o R2 deu 1, 2 e 2, também reprovando. Automático e humano coincidem na decisão, mas por motivos diferentes: o F1 cai por falta de palavras em comum com a referência; o humano, por falta de título e de declaração explícita de insuficiência.
5. **Paráfrase correta pontua menos.** CT06 (B) preserva a informação de CT01 com outras palavras ("pegar livros emprestados sem custo") e copia os erros de digitação da fonte ("funsiona", "as 8h"), e o F1 cai de 0,782 (CT01) para 0,659. Continua acima de τ, mas mostra que o F1 mede sobreposição de palavras, não correção.
6. **Sensibilidade ao texto comparado.** Retirando `url` e `links`, o F1 de todas as saídas não vazias cai (de 0,809 para 0,712 em CT03; de 0,467 para 0,200 em CT05), mas nenhum sinal automático muda. CT06/B fica em 0,516, muito perto de τ, e CT05/B passa a ficar bem abaixo dele; esses dois casos são os mais sensíveis à escolha do texto comparado.

5.4 Concordância automático–humano (M3)

Concordância = decisões iguais / 12, calculada por `concordancia_auto_humano.py` a partir da decisão humana de cada saída (R1 da

Pessoa 6, que é a decisão operacional das 12 saídas). A decisão foi montada por `montar_decisao_humana.py` a partir de `avaliacao_humana_R1.xlsx`.

- **Concordância automático–humano: 12/12.**
- Aprovação humana: A 1/6 e B 5/6. Sinal automático: A 1/6 e B 5/6.
- **Divergências automático–humano: nenhuma.** O caso-limite analisado é CT05/B (seção 5.3): as duas decisões reprovam, mas por razões distintas.
- **Sensibilidade ao R2:** nas quatro saídas revisadas pela Pessoa 7 (CT01 e CT05, nas duas versões), a decisão do R2 é igual à do R1 (4/4). Usar o R2 no lugar do R1 nessas quatro saídas também resulta em 12/12. Notas e falha crítica, porém, foram idênticas em apenas 1 das 4 (CT01/B); CT01/A e CT05/A diferem na falha crítica (R1 = 0, R2 = 1 para a saída vazia) e CT05/B difere na relevância (R1 = 1, R2 = 2). Nenhuma dessas diferenças altera a aprovação. O consenso formal R1–R2 e a concordância R1–R2 (iguais/4) ficam com a Pessoa 7.
- **Leitura cuidadosa:** 5 dos 12 acordos vêm das saídas vazias de A, em que as duas decisões reprovam de forma trivial. Entre as 7 saídas com conteúdo, o acordo é de 7/7, mas é uma amostra pequena.
- **Falha crítica:** o R1 registrou falha crítica = 0 como valor provisório, por não ter localizado a regra da seção 1.2. Nas saídas já reprovadas por nota isso não muda a decisão. A decisão formal de avanço depende dessa regra em CT01 e CT05 na versão B, em particular se `titulo = null` em CT05/B conta como omissão de chave obrigatória.

5.5 Limitações da medida

- O F1 lexical não verifica fatos: trocar "10/11" por "11/11" mantém quase todos os tokens, mas muda a resposta.
- Penaliza paráfrases corretas e markdown inserido no texto; recompensa cópia da fonte, inclusive erros de digitação.
- Não avalia a validade do JSON nem o preenchimento correto dos campos; `url` e `links` copiados corretamente elevam o F1 sem informar nada sobre a qualidade do resumo.
- Seis casos, uma execução por caso e versão, e CT06 derivado de CT01 (não é observação independente) impedem generalizar. A comparação entre versões vale só para este conjunto.

6. Versionamento, manifesto e ciclo de vida

6.1 Versões A e B. As duas versões do fluxo foram preservadas em pastas identificáveis do repositório (`atividade3/versoes/A` e `atividade3/versoes/B`). A versão A é o baseline: prompt P1 (“Extraia o título, a URL, o conteúdo e os links desta página.”) com as cinco regras de preenchimento. A versão B muda um único fator, o prompt: usa o P2, que mantém as cinco regras e acrescenta objetivo, contexto, restrições de saída (somente JSON, sem texto extra, não inventar informações, preservar valores, datas e números) e formato dos campos. O diff entre as duas pastas mostra diferença apenas no texto do prompt (e na linha que o seleciona) e no manifesto. Schema, validador, modelo, temperatura 0 e fontes são os mesmos.

6.2 Manifestos. Cada versão tem um `manifesto.yaml` com código/commit, prompt, modelo/revisão e parâmetros, fonte/contexto, casos/referências, rubrica/limiar e resultados, além da data de registro [08/11/2026] e das limitações de congelamento. Entre A e B mudam apenas o prompt e a descrição da mudança.

6.3 Rastreabilidade. A cadeia caso → saída → nota → decisão → versão segue `casos/referencias.json` → `execucoes/<versão>/<caso>/saida_bruta.json` → avaliações R1/R2 → decisão humana final → versão. Saídas e notas ficam em arquivos separados, e as saídas vazias (5 em A) foram registradas, não descartadas. [Figura: ciclo de vida, Pessoa 7]

6.4 Reconstrução e o que não foi congelável. Com o manifesto é possível reexecutar o mesmo código, prompt, parâmetros e fontes (HTML fixo em localhost:8000). Não foi possível congelar: [a revisão do checkpoint Qwen/Qwen3-4B, se o hash da revisão não foi registrado]; o determinismo, pois mesmo com temperature 0 a execução em GPU (Colab, Tesla T4) pode variar; o ambiente efêmero do Colab; e o fato de o script aproveitar só o primeiro chunk válido. Por isso as 12 saídas brutas guardadas, e não a reexecução, são a evidência primária.

6.5 Retorno à versão A. Se B causar problema, volta-se à A restaurando a pasta/commit [versao-A], sem alterar casos nem avaliações. Sinais a acompanhar: taxa de saídas vazias, conformidade com o schema (raiz objeto, título não nulo) e falha crítica em CT01 e CT05.

7. Avaliação Humana Secundária (R2)

Após a primeira avaliação humana em R1, um segundo avaliador humano se propôs a analisar as saídas geradas pelo modelo nas versões A e B, sem consultar o R1 e nem entrar em contato com o primeiro avaliador antes. Esta segunda avaliação foi

realizada somente em base dos casos de teste CT-01 e CT-05, que são considerados críticos para a aprovação/bloqueio da versão B. Além disso, uma segunda avaliação humana realizada por uma pessoa diferente permite perceber as sutis diferenças e nuances características da percepção humana na avaliação dos casos de teste. Tais características foram percebidas neste trabalho e estão aqui descritas.

7.1 Resultados da R2

O resultado da segunda avaliação humana está descrito na tabela abaixo.

ct	versao	correcao	relevancia	suporte	falha_critica	justificativa	resultado
CT-01	A	0	0	0	1	Saída vazia	Reprovado
CT-01	B	2	2	2	0	Saída correta	Aprovado
CT-05	A	0	0	0	1	Saída vazia	Reprovado
CT-05	B	1	1	2	0	Título ausente	Reprovado

7.2 Comparação com R1

Os resultados obtidos demonstram um claro consenso entre o R1 e o R2. Ambos os avaliadores obtiveram o mesmo resultado final, em que a versão B reprova no CT-05 por falhar em extrair o título da página.

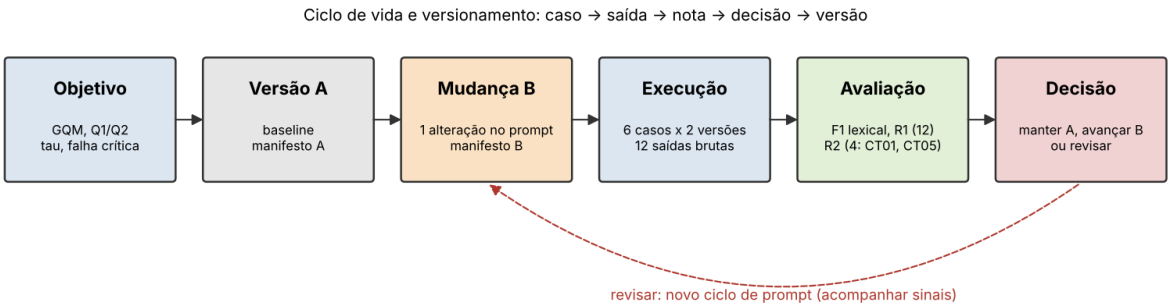
Apesar desse consenso, existem divergências entre as duas avaliações no quesito da interpretação do que seria considerado como “falha crítica”. Sob o ponto de vista de R2, CT-05 na versão A retornar uma saída vazia é uma clara falha crítica, pois apesar da página possuir pouco conteúdo/conteúdo insuficiente, o modelo deveria ser capaz de executar a sua tarefa, mesmo com a limitação imposta. Tal observação não se encontra na avaliação R1.

Essa divergência demonstra a característica sutil das nuances da avaliação humana, principalmente se comparadas a avaliações automatizadas baseadas em algoritmos. Um script de computador dificilmente irá produzir uma saída diferente mesmo após ser executado diversas vezes, enquanto que dois avaliadores humanos frequentemente produzem análises diferentes, e possivelmente discordam até de si mesmos.

7.3 Diagrama de Ciclo de Vida

Mesmo que a versão B ainda não produza o resultado esperado em 100% dos casos de teste observados, as avaliações, tanto automáticas quanto humanas, demonstraram que ela é claramente uma versão superior à versão A. Isso indica que ela é uma forte candidata para se tornar a próxima *baseline* do projeto após um processo de refinamento progressivo.

A imagem abaixo demonstra o diagrama de ciclo de vida do projeto.



Este diagrama ilustra o processo ocorrido durante a elaboração dessa atividade. Foi criada uma versão “A” como baseline, e em seguida, uma versão B, criada a partir de uma mudança na versão A, foi colocada em um ambiente de testes e avaliada tanto por humanos quanto por forma automatizada. Ao final das avaliações, foi tomada uma decisão informada quanto à situação da versão B. Se B falhar em qualquer ponto das avaliações, ele retorna para um novo ciclo de revisão para percorrer todos os testes e avaliações do processo, até se tornar a próxima baseline do projeto.

O resultado deste processo é um projeto com refinamento progressivo de versões, onde cada versão é composta por uma melhoria significativa que é testada, avaliada e criteriosamente decidida a partir da versão anterior, tanto por códigos automatizados quanto por humanos.

Declaração Uso de IA

Rivaldo José Nascimento dos Santos

Sintetização das avaliações realizadas para transformar em indicadores.

Letícia Rezende dos Santos

Elaboração dos casos de teste e estruturação das pastas para os JSONs e logs gerados a partir da execução dos testes. Revisão da documentação para tabela de casos de teste.

Daniel Rodrigo Ferreira dos Santos

Explicação conceitual dos requisitos da atividade proposta.

Maria Rita Melo de Souza

Elaboração das páginas utilizadas como entrada nos casos de teste, e apoio na estruturação dos casos de teste e saídas esperadas.

Carlos Eduardo Laurentino dos Santos

Utilizei o ChatGPT, como apoio na organização das ideias, elaboração e revisão dos textos, esclarecimento de dúvidas e auxílio na estruturação dos casos de teste. A execução dos testes, análise dos resultados e decisões apresentadas no trabalho foram realizadas por mim.

Brício Thyers de Gois Macedo

Criação de slides para apresentação, readme explicativo das metricas e arquivos de scripts criados.

Lucas Conceição Celestino

Criação do Slide, escrita do código, ajuda nas métricas e no roteiro.