UNIVERSIDADE FEDERAL DE SERGIPE
QUALIDADE DE SOFTWARE

VERIFICAÇÃO, SEGURANÇA E MELHORIA DE APLICAÇÕES DE IA GENERATIVA

CRAWL4AI

Extração web e rastreabilidade para RAG





DISCENTES: BRÍCIO THYERS DE GOIS MACEDO • CARLOS EDUARDO LAURENTINO DOS SANTOS • DANIEL RODRIGO FERREIRA DOS SANTOS • LETÍCIA REZENDE DOS SANTOS • LUCAS CONCEIÇÃO CELESTINO • MARIA RITA MELO DE SOUZA • RIVALDO JOSÉ NASCIMENTO DOS SANTOS

PLANEJAMENTO EXPERIMENTAL GQM

LETÍCIA REZENDE

Objetivo de Avaliação

Comparar o fluxo **Versão A** (baseline) com a **Versão B** (prompt com restrições e tipagem) no Crawl4AI.

Q1 — Efeito da Mudança: Verifica se a Versão B entrega respostas mais adequadas.

Q2 — Validade do Sinal: Avalia se o F1 automático concorda com o julgamento humano.

QUESTÃO	MÉTRICA & FÓRMULA	DENOMINADOR	LIMITAÇÃO DECLARADA
Q1 (Humano)	**Taxa de Aprovação** 3 notas 2 e zero falhas críticas	`6 por versão`	Subjetividade e amostra reduzida (N=6).
Q2 (Automático)	**F1 Lexical por Tokens** $2 \times (P \times R) / (P + R)$	`Tokens comuns`	Penaliza paráfrases factualmente corretas.
Q2 (Sinal)	**Concordância Auto-Humano** Decisões Idênticas / Total	`12 saídas`	Depende do limiar tau fixado antes do teste.

QUALIDADE DE SOFTWARE • UFS • 2026.2

CRITÉRIOS E DECISÃO EXPERIMENTAL

LETÍCIA REZENDE

Limiar & Aprovação

LIMIAR AUTOMÁTICO (A PRIORI)

$\tau = 0.50$

F1 ≥ 0.50 aprova sem ajuste posterior

Aprovação Humana Estrita:
Exige simultaneamente nota máxima (2/2) em Correção, Relevância e Suporte.

Aprovação: C=2 ∧ R=2 ∧ S=2 ∧ FC=0

Falha Crítica (FC=1)

Gera reprovação humana imediata caso ocorra qualquer uma das 4 violações:

1. **Alucinação Factual:** Afirmação sem suporte no trecho.
2. **Não Abstenção (CT05):** Inventar resposta sem evidência.
3. **URL Quebrada/Falsa:** Link fora do padrão RFC.
4. **Violação Estrutural:** JSON malformado ou campos nulos.

Qualquer ocorrência anula a pontuação humana

Protocolo de Decisão

Condição de Avanço (B)
Taxa de Aprovação Humana de B > A **E** zero falhas críticas nos casos CT01 e CT05.

Condição de Bloqueio
Presença de falha crítica em casos essenciais ou regressão de qualidade mantém a **Versão A**.

Decisão Experimental: Avançar B vs. Manter A

MARIA RITA

CASOS DE TESTE

CT01-CT04 cobrem quatro casos funcionais.
CT05 verifica uma página sem informação e exige não inventar dados.
CT06 varia CT01 com erros de digitação e paráfrase.
As fontes são HTML sintético e estático, servidas em localhost:8000, iguais para A e B.

ID	Tipo	O que testa
CT01	Funcional	Horário e prazo
CT02	Funcional	Preço (R$ 18,90)
CT03	Funcional	Datas do evento
CT04	Funcional	Ignorar menu e rodapé
CT05	Sem evidência	Não inventar dados
CT06	Variação de CT01	Erros de digitação

AVALIAÇÃO HUMANA

MARIA RITA

ID	Pergunta de verificação	Resposta esperada
CT01	Qual o horário de funcionamento e o prazo de empréstimo?	Segunda a sexta, 8h às 17h; empréstimo gratuito por até 14 dias
CT02	Qual o preço e a disponibilidade do produto?	R$ 18,90; em estoque
CT03	Quando e onde ocorre o evento, e até quando vão as inscrições?	18 a 20 de novembro de 2026, Auditório B; inscrições até 14 de novembro
CT04	Quantos computadores tem o laboratório e quando foi inaugurado?	20 computadores; inaugurado em 3 de setembro
CT05	Qual o horário de atendimento da secretaria?	Não há informação na página; o correto é declarar que a informação é insuficiente
CT06	Mesma pergunta de CT01	Mesma resposta de CT01, apesar dos erros de digitação e da paráfrase

LUCAS

VERSÕES A E B: UMA ÚNICA MUDANÇA

Versão A (baseline)

Prompt P1 e cinco regras de preenchimento.

Pede título, URL, conteúdo e links da página. As regras dizem o que entra em cada campo e proíbem inventar dados.

Versão B (com restrições)

Prompt P2: mantém as cinco regras e acrescenta

- Objetivo, contexto e formato explícitos
- Retornar só JSON, sem texto extra
- Não inventar; preservar valores, datas e números

Prova: o diff entre as pastas versoes/A e versoes/B muda só o texto do prompt e o manifesto. Schema, validador e temperatura 0 são idênticos.

LUCAS

MANIFESTO: O QUE FICA REGISTRADO

Campo	Registro	Em A e B
Código	Mesmo script, schema e validador; uma pasta por versão (versoes/A e versoes/B)	Igual
Prompt	P1 na versão A; P2 na versão B	Muda
Modelo	OpenRouter (API gratuita), o mesmo em A e B; revisão não congelável	Igual
Parâmetros	temperature 0, extração por schema, chunks de 1000 tokens, cache desligado (BYPASS), Crawl4AI 0.9.3	Igual
Fonte	HTML sintético fixo (CT01 a CT06), servido em localhost:8000	Igual
Do grupo	Casos e referências (Pessoa 2), rubrica e τ = 0,50 (Pessoa 1), resultados (Pessoas 4, 5 e 6)	Igual

LUCAS

O QUE NÃO FOI CONGELÁVEL

Dá para reconstruir uma saída usando o manifesto?

Congelado

- Código, prompt, schema e validador em versoes/A e versoes/B
- temperature 0 e parâmetros de extração
- Fontes HTML sintéticas e fixas
- Casos, referências, rubrica e τ antes da bateria

Não congelável

- Determinismo: com temperature 0 a saída ainda pode mudar
- Tier gratuito: 20 req/min e 50 req/dia
- Só o primeiro chunk válido é aproveitado

Resposta: dá para refazer a execução nas mesmas condições, mas não há garantia de obter a mesma saída.

AMBIENTE E CONDIÇÕES COMPARÁVEIS

1. Fontes HTML sintéticas e estáticas, servidas em **localhost:8000**.
2. Mesmo modelo, parâmetros e fontes em A e B.
3. Só o fator principal muda: o prompt da versão B.
4. Projeto, provedor e base já disponíveis, sem infraestrutura nova.

12 EXECUÇÕES: 6 CASOS × 2 VERSÕES

Caso	O que testa	Versão A	Versão B
CT01	Horário e prazo	vazia	ok
CT02	Preço (R$ 18,90)	vazia	ok
CT03	Datas do evento	ok	ok
CT04	Ignorar menu e rodapé	vazia	ok
CT05	Não inventar dados	vazia	ok
CT06	Erros de digitação (variação de CT01)	vazia	ok

Progresso: 12 de 12 execuções concluídas · 5 saídas vazias na versão A

ACHADO: SAÍDAS VAZIAS NA VERSÃO A

Versão A (baseline)

5 de 6 casos retornaram lista vazia **[]**: CT01, CT02, CT04, CT05 e CT06.

Só CT03 gerou dados.

Versão B (prompt com restrições)

6 de 6 casos com dados corretos das fontes.

Em CT05, declarou que a página está em manutenção, sem inventar dados.

QUALIDADE DE SOFTWARE • UFS • 2026.2 • MÉTRICA AUTOMÁTICA

F1 LEXICAL: COMO É CALCULADO

BRICIO

1

PARES PARA COMPARAR

Referência humana (Pessoa 2) × saída bruta (Pessoa 4): 6 casos × 2 versões = 12 pares.

2

TOKENIZAÇÃO FIXA

Unicode NFC, minúsculas e palavras. Interseção de multiconjuntos: repetir palavra não ajuda.

3

PRECISÃO, RECALL E F1

Cada saída recebe três números calculados com as fórmulas abaixo.

4

SINAL COM τ = 0,50

F1 ≥ τ → aprova. O limiar foi fixado antes da bateria e não foi ajustado.

PRECISÃO (P)

P = comuns / tokens da resposta

Quanto do que o modelo escreveu está na referência.

RECALL (R)

R = comuns / tokens da referência

Quanto da referência o modelo cobriu.

F1 LEXICAL

F1 = 2 · P · R / (P + R)

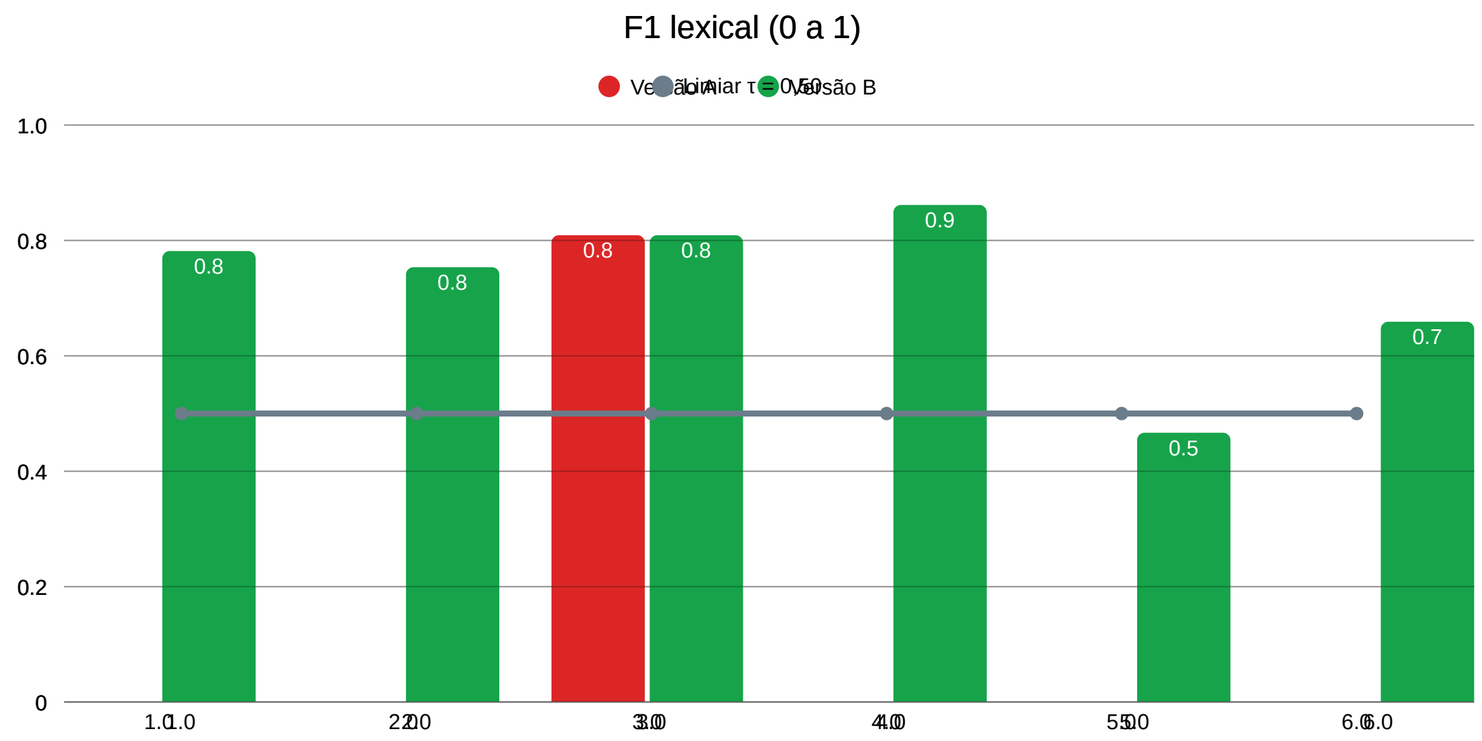
Média harmônica: só é alta se P e R forem altas.

✓ **Saída vazia ou sem palavras em comum → F1 = 0. As 12 saídas entram na tabela, inclusive as vazias: nada é descartado.**

QUALIDADE DE SOFTWARE • UFS • 2026.2 • MÉTRICA AUTOMÁTICA

RESULTADO: F1 POR CASO E VERSÃO

BRICIO



VERSÃO A (BASELINE)

0,135

F1 médio · mediana 0,000
1/6 aprovadas pelo sinal

VERSÃO B (PROMPT COM RESTRIÇÕES)

0,722

F1 médio · mediana 0,768
5/6 aprovadas pelo sinal

! **A diferença de médias vem das 5 saídas vazias de A (F1 = 0). Entre as saídas preenchidas, o F1 vai de 0,47 a 0,86.**

QUALIDADE DE SOFTWARE • UFS • 2026.2 • AUTOMÁTICO × HUMANO

F1 × AVALIAÇÃO HUMANA

BRICIO

CASO	A · F1	A · AUTO	A · HUMANO	B · F1	B · AUTO	B · HUMANO
CT01	0,000	reprova	reprova	0,782	aprova	aprova
CT02	0,000	reprova	reprova	0,754	aprova	aprova
CT03	0,809	aprova	aprova	0,809	aprova	aprova
CT04	0,000	reprova	reprova	0,862	aprova	aprova
CT05	0,000	reprova	reprova	0,467	reprova	reprova
CT06	0,000	reprova	reprova	0,659	aprova	aprova

CONCORDÂNCIA AUTO–HUMANO

12/12

decisões iguais em 12 saídas

Aprovação humana: A 1/6 · B 5/6
Sinal automático: A 1/6 · B 5/6

Regra: o sinal aprova se F1 ≥ 0,50; a decisão humana aprova com três notas 2 e nenhuma falha crítica.

ONDE O F1 MOSTRA SEUS LIMITES

BRICIO

CASO-LIMITE · CT05 / B

0,467

Fica abaixo de τ, perto do limiar. O modelo não inventou dados, mas copiou a mensagem da página e deixou título null; humano: 1/1/2. O resultado depende da redação da referência de abstenção.

PARÁFRASE · CT06 / B

0,659

Preserva a informação de CT01 (0,782) com outras palavras e cai no F1. Erros de digitação copiados da fonte quase não pesam: o F1 mede sobreposição, não correção.

SEM EFEITO DO PROMPT · CT03

0,809

As saídas de A e B são idênticas (mesmo hash). O prompt B não muda este caso: a melhora de B vem dos outros cinco.

! **O F1 não verifica fatos: trocar “prazo 10/11” por “11/11” mantém F1 ≈ 0,86 (exemplo dos nossos testes).**

✓ **Os 12/12 contam com 5 saídas vazias em A. Use o F1 como sinal auxiliar; a decisão segue humana.**

QUALIDADE DE SOFTWARE • UFS • 2026.2

AVALIAÇÃO HUMANA PRINCIPAL

RIVALDO JOSÉ

ESCOPO	MÉTODO	REGRA DE APROVAÇÃO
12 saídas 6 casos de teste (CT01 a CT06) × 2 versões (A e B)	**3 critérios** Correção, relevância e suporte Notas independentes de 0 a 2	**Nota Max (2,2,2)** Regra operacional: aprovação requer nota máxima e 0 falhas críticas

Procedimento de Avaliação

- Conferência minuciosa dos contextos enviados ao modelo, saídas brutas, fontes HTML e referências.
- 12 julgamentos registrados com notas individuais, evidências e justificativas documentadas em R1.csv.
- Execução estritamente passiva: nenhum teste foi reexecutado e os arquivos originais foram preservados.

RESULTADOS: VERSÃO A VS VERSÃO B

RIVALDO JOSÉ

VERSÃO A (BASELINE)	VERSÃO B (EVOLUÇÃO)	GANHO DE QUALIDADE
16,7%	**83,3%**	**+66,6%**
1 de 6 aprovadas 5 de 6 saídas vazias [ ]	5 de 6 aprovadas Recuperação de dados precisos	Taxa de aprovação humana em conteúdo extraído

Destaques da Comparação

- **Versão A:** Retornou lista vazia em 5 dos 6 casos (CT01, CT02, CT04, CT05 e CT06), obtendo nota zero.
- **Versão B:** Extração completa e precisa em 5 casos, mantendo preços, datas, prazos e filtrando menuz/rodapés.
- **Robustez no CT06:** A Versão B interpretou corretamente a intenção mesmo com erros ortográficos da fonte.

A Versão B apresentou evolução substancial na extração de conteúdo relevante e suportado pelas fontes.

ANÁLISE DETALHADA DOS CASOS

DESEMPENHO POR CASO DE TESTE

RIVALDO JOSÉ

CASO	DOMÍNIO / DESAFIO	VERSÃO A (C/R/S)	VERSÃO B (C/R/S)	OBSERVAÇÃO PRINCIPAL
CT01	Horários e Empréstimos	0/0/0	2/2/2	B extraiu horários, prazos e links corretamente.
CT02	Preço e Estoque	0/0/0	2/2/2	B preservou valor exato (R$ 18,90) e disponibilidade.
CT03	Datas e Local de Evento	2/2/2	2/2/2	Único caso com extração correta em ambas as versões.
CT04	Filtro de Artigo Principal	0/0/0	2/2/2	B isolou o conteúdo limpo, sem navegação ou rodapé.
CT05	Página em Manutenção	0/0/0	1/1/2	B não alucinou, mas deixou `titulo: null` e omitiu alerta.
CT06	Resiliência a Erros Digitação	0/0/0	2/2/2	B interpretou a consulta perfeitamente (variação de CT01).

⚠ **Notas exibidas no formato (Correção / Relevância / Suporte). Apenas CT05 ficou abaixo de 2/2/2 na Versão B.**

QUALIDADE DE SOFTWARE • DIAGNÓSTICO FINAL

INCOMPATIBILIDADE ESTRUTURAL E CONCLUSÃO

RIVALDO JOSÉ

INCOMPATIBILIDADE DE ESQUEMA	CRITÉRIO DE CRITICIDADE	STATUS DA APROVAÇÃO
Raiz [ ]	**Pendente**	**Provisório**
Saídas geradas como lista Esquema exige Objeto na raiz	Sem documento de critério Falha crítica mantida como 0*	Aprovação operacional sujeita à validação formal

Síntese e Recomendações

- **Validade Sintática vs Estrutural:** Os registros marcam json_valido=true, mas há desvio do page_schema.json.
- **Conclusão Qualificada:** A Versão B demonstra clara superioridade em extração textual, porém necessita ajuste na estrutura de saída.
- **Próximo Passo:** Definir o limiar formal de falhas críticas com a equipe para fechar a aprovação global definitiva.

Daniel

Segunda Avaliação Humana (R2)

- Após a execução dos casos de teste e da primeira avaliação humana (R1), foi executada uma segunda avaliação humana (R2).

- A segunda avaliação humana foi realizada apenas sob os casos de teste CT-01 e CT-05, e sob as versões A e B dos testes.

- Essa avaliação serviu como base de um comparativo entre a primeira avaliação humana e o critério de avanço/bloqueio da versão “B”.



Daniel

Segunda Avaliação Humana (R2)

ct	versao	correcao	relevancia	suporte	falha_critica	justificativa	resultado
CT-01	A	0	0	0	1	Saída vazia	Reprovado
CT-01	B	2	2	2	0	A saída atendeu a todos os requisitos do teste. Ela é correta e funcional	Aprovado
CT-05	A	0	0	0	1	Apesar da página estar em manutenção, ela ainda possui título e conteúdo	Reprovado
CT-05	B	1	2	2	0	A saída está correta, mas o título da página está ausente	Reprovado

Daniel

Comparação com R1

atividade3/execucoes/B/CT05/saida_bruta.json

```
@@ -0,0 +1,8 @@
+ [
+     {
+         "titulo": null,
+         "url": "http://localhost:8000/ct05.html",
+         "conteudo": "Estamos atualizando esta página. Volte em breve.",
+         "links": []
+     }
+ ]
```

Execução do CT-05 na versão “B“

- Ambas avaliações obtiveram o mesmo resultado final.
- Na versão “A”, CT-01 e CT-05 reprovam. Na versão “B”, CT-01 é aprovado, porém CT-05 é reprovado por falhar em obter o título da página.
- Mesmo após a falha, a versão “B” demonstra uma clara evolução da versão “A”

Daniel

Diagrama de Ciclo de Vida

